

Engine SDD reutilizável

DeepSeek Harness + OpenAI para transformar requisitos em software verificável, auditável e com custo controlado.

Arquitetura, governança, operação e defesa técnica

A tese: separar inteligência de execução

O engine é o control plane; o software entregue permanece determinístico e independente de modelos.

Especificação antes de código

Cada mudança começa por requisitos, critérios de aceite e dependências versionados.

IA no lugar certo

Modelos ajudam a projetar e implementar; validação, runtime e release não dependem deles.

Prova antes de confiança

Testes, hashes, ledger e CI tornam o resultado reproduzível e discutível.

Por que é o melhor ajuste?

Reduz acoplamento, evita IA em produção, contém risco por mudança e preserva evidência suficiente para auditoria e evolução.

Fronteira do repositório

engine/

Control plane reutilizável
Harness, SDD, políticas, custos, histórico, gates

Selecionar



projects/<project-id>/

Contexto isolado
Specs, código, testes, evidências e runbook próprios

Limite realpath

O seletor rejeita traversal e links simbólicos fora da raiz do projeto.

Instalação separada

O projeto não é workspace npm: dependências e gates não vazam entre domínios.

Runtime model-free

O artefato final usa apenas Node, SQLite e filesystem; não carrega Harness/OpenAI.


Autoridade → spec → evidência



O ganho central

Uma decisão deixa de ser “o agente achou melhor” e vira uma cadeia verificável: requisito → AC → arquivo → teste → release.

Ciclo de entrega orientado por specs



FLUXO REPRODUZÍVEL

```
npm run project:prepare -- --project <id> --change <change> --spec <SDD>
npm run project:run    -- --project <id> --change <change> --spec <SDD>
npm run project:cost   -- --project <id>
```

DeepSeek Harness como arquitetura, não como modelo



Pin: @deepseek-ai/deepseek-harness 0.1.2-rc.1 · developer preview · smoke tests de compatibilidade

Composabilidade espaço-temporal

TEMPORAL

Efeitos reversíveis

Ao remover um componente, o runtime desfaz suas transformações em ordem LIFO. Ativação, teardown e hot replacement tornam-se disciplinados.

ESPACIAL

Coefeitos reativos

Dependências declaradas reagem a mudanças de contexto: componentes ativam e desativam sem coordenação global rígida.

Impacto prático: trocar provider, retenção, ferramentas ou política de custo sem reescrever o loop inteiro.

Roteamento: qualidade suficiente ao menor custo

LUNA

Economy / low
Ingestão, normalização, triagem,
formatação e tarefas mecânicas

TERRA

Default / medium
Projeto SDD, implementação,
integração e revisão principal

SOL

Escalation / high
Arquitetura difícil, segurança e
adjudicação de alto risco — exige
aprovação

Política

O modelo não é status: é uma decisão econômica registrada. Sol nunca é fallback automático; aliases móveis são rejeitados.

Default global: openai/gpt-5.6-terra · reasoning medium · contexto limitado a 272k

Custo por tentativa e por mudança

$$\text{custo} = \text{input} \times \text{tarifa} + \text{cache-read} \times \text{tarifa} + \text{cache-write} \times \text{tarifa} + \text{output} \times \text{tarifa}$$


Modelo	Input	Cache read	Cache write	Output
Luna	\$0,20	\$0,02	\$0,25	\$1,20
Terra	\$2,00	\$0,20	\$2,50	\$12,00
Sol	\$4,00	\$0,40	\$5,00	\$20,00

USD por 1 milhão de tokens · Standard/default · snapshot 06/09/2026

Regras críticas

Inteiros em nanodólares; reasoning já está em output; >272k reprecifica toda a requisição; retries também custam; uso ausente mantém reserva não reconciliada.

Reserva, settlement e recuperação limitada



429 reconhecido

até 3 tentativas · atraso $\leq 60s$ · mesmo
lock/escopo/árvore · logs por tentativa

Falha segura

exhaustion=75 · Ctrl-C=130 · SIGTERM e graça antes de
SIGKILL · nenhum fallback para Sol

Isolamento e segurança por construção

Escopo

project ID allow-listed + realpath containment

Segredos

somente aliases de credencial; nunca a chave

Rede

CI offline; chamadas só no control plane autorizado

Runtime

nenhum SDK/provider/model no software entregue

Release

secret scan + ledger + SDD + testes + hashes

Histórico SDD portátil sem expor o que é privado

25

runs reconciliados

17

sessões duráveis

86

arquivos publicados

SHA-256

integridade do manifesto

Inclui

prompts observáveis · mensagens · ferramentas · retries
· stdout/stderr · resultado · usage

Exclui

chain-of-thought · replay cifrado · credenciais · PDFs ·
DB/fixtures brutos · symlinks · paths locais

Snapshot imutável · cutoff 2026-09-06T17:58:48Z · manifesto d1a417f5...

RTK e Serena: economizar contexto, preservar julgamento

RTK

Proxy de shell

Filtra, agrupa, trunca e deduplica logs antes de entrarem no contexto. Reduz ruído de rg, git, npm test e outros comandos.

Mede redução de output; não promete a mesma redução na fatura.

SERENA

MCP semântico

Usa LSP, símbolos e relações para localizar o contexto necessário e editar com precisão, em vez de ler arquivos inteiros.

Opcional e fora do runtime do catálogo.

BOOTSTRAP

```
rtk init -g --codex # ativar integração global
rtk gain           # ver economia estimada
# Serena: configurar MCP + .serena/project.yml
```

Reprodução limpa e operação diária


CLEAN CLONE

```
git clone https://github.com/sergiofigueras/vtex-coding-challenge.git
cd vtex-coding-challenge
npm ci
npm --prefix projects/catalog-consolidation ci
npm run check
npm --prefix projects/catalog-consolidation run check
```

NOVO PROJETO / NOVA MUDANÇA

```
npm run project:create -- --project <novo-projeto>
npm run project:prepare -- --project <id> --change <change> --spec <SDD>
npm run project:run -- --project <id> --change <change> --spec <SDD>
npm run project:cost -- --project <id>
```

Gates que tornam a entrega defensável

**6/6**

specs do engine verificadas

10/10

specs do projeto verificadas

9b2245e

commit validado no CI

Custo observado: transparência, não maquiagem

US\$ 8,79349175

custo conhecido do catalog-consolidation

US\$ 14,1416064

estimativas/reservas registradas

Não somar

Estimativa/reserva não é custo adicional; settlement substitui a incerteza quando usage chega.

Não ocultar

Tentativas falhas e usage ausente permanecem como unavailable/unreconciled, nunca viram custo zero.

Atribuir

Cada evento leva change ID, specs, modelo, tokens, preço e hash anterior; o rollup liga custo a resultado.

39 change IDs do projeto no relatório atual · valores em USD · pricebook standard-assumed

Alternativas rejeitadas — e por quê

Agente monolítico

Mistura contexto, política e execução; dificulta substituição e auditoria.

Plugins + seams

Um prompt gigante

Falha de contexto e critérios implícitos; difícil reproduzir.

Grafo de specs

Modelo mais caro sempre

Eleva custo sem elevar valor em tarefas mecânicas.

Roteamento econômico

Sem ledger

Só há estimativa agregada; retries e mudanças somem.


Eventos append-only

IA no runtime

Disponibilidade, variância e custo entram em produção.

Runtime determinístico

A solução é forte porque conecta



Não é “IA que gera código”. É uma fábrica de mudanças pequenas, rastreáveis, reversíveis e economicamente observáveis.

Fontes principais: README.md · engine/README.md · arXiv:2608.25512 · DeepSeek Harness · OpenAI model pages · RTK · Serena